

LN1. 引言

张晓今

计算机学院数据挖掘与机器学习实验室

华中科技大学 Hopcroft 计算科学研究中心

邮箱: xiaojinzhang@hust.edu.cn

2026 年 03 月



- ① 评估方式
- ② 教材和参考书
- ③ 引 言
 - 什么是机器学习?
 - 监督学习
 - 无监督学习
- ④ 机器学习的基本术语
- ⑤ 发展历程
- ⑥ 主要的学术会议和期刊
- ⑦ 机器学习算法对为人处事的启发

- 1 评估方式
- 2 教材和参考书
- 3 引 言
 - 什么是机器学习?
 - 监督学习
 - 无监督学习
- 4 机器学习的基本术语
- 5 发展历程
- 6 主要的学术会议和期刊
- 7 机器学习算法对为人处事的启发

考查

- 机器学习：40 学时，理论课，2.5 学分
 - 机器学习实验：16 学时，实验课，0.5 学分
 - 4 次实验课，2 次线上，2 次线下
-
- 理论课：
 - 课堂参与或作业 (30%)
 - 考试 (70%)

学术诚信 (Academic Integrity)

- 请独立完成作业和实验
- 不要 copy 其他同学的代码
- 不要 copy AI 自动生成的文字和代码 (如 ChatGPT、DeepSeek)

- ① 评估方式
- ② 教材和参考书
- ③ 引 言
 - 什么是机器学习?
 - 监督学习
 - 无监督学习
- ④ 机器学习的基本术语
- ⑤ 发展历程
- ⑥ 主要的学术会议和期刊
- ⑦ 机器学习算法对为人处事的启发

- 教材:

- 机器学习讲义 (何琨)
- 统计学习方法 (李航), 清华大学出版社

- 参考书:


- MLaPP: Machine Learning: a Probabilistic Perspective, by K. Murphy, MIT Press, 2012
- ESL: The Elements of Statistical Learning, by Hastie, Tibshirani, and Friedman, Springer, 2009
- C. Bishop, Pattern Recognition and Machine Learning, Springer, 2007
- 机器学习 (周志华), 清华大学出版社

- ① 评估方式
- ② 教材和参考书
- ③ 引 言
 - 什么是机器学习?
 - 监督学习
 - 无监督学习
- ④ 机器学习的基本术语
- ⑤ 发展历程
- ⑥ 主要的学术会议和期刊
- ⑦ 机器学习算法对为人处事的启发

什么是机器学习?

机器学习

- 人工智能的一个分支
- 关注设计和开发算法以使计算机能够根据经验数据来不断改进其行为
- 由于智能需要知识，因此计算机必须获取知识
- 通过经验改进其在一些任务上的性能的算法研究
- 利用示例数据或过去的经验来优化某个评估指标
- 统计学中的角色：从样本中进行推断
- 计算机科学中的角色：解决优化问题的高效算法




以垃圾邮件的检测为例，核心是程序，但最终的目标是获得答案输出。

什么是机器学习

Mitchell, 1997

- A computer program A , learn from experience E , w.r.t some tasks T , and performance measure P . If E helps improve the performance.
- 假设用 P 来评估计算机程序在某任务类 T 上的性能，若一个程序通过利用经验 E 在 T 中任务上获得了性能改善，则称关于 T 和 P ，该程序对 E 进行了学习
- 利用经验来改善系统自身的性能
- 基于统计和优化



监督学习是一种算法，它从一个训练数据集中学习。我们知道正确的答案或期望的输出，算法利用给定的数据集进行预测，并由 **supervisor**（监督者）进行纠正。当算法达到可接受的性能水平时，学习过程停止。

监督学习有两种类型 - 分类 (classification) 和回归 (regression)。

垃圾邮件过滤

data	prediction
Osman Khan to Carlos sounds good rok Carlos Guestrin wrote: Let's try to chat on Friday a little to coordinate and more on Sunday in person? Carlos	Spam vs. Not Spam
Welcome to New Media Installation: Art that Learns Carlos Guestrin to 10615-announce, Osman, Miche show details 3:15 PM (8 hours ago) Reply Hi everyone, Welcome to New Media Installation: Art that Learns The class will start tomorrow. ***Make sure you attend the first class, even if you are on the Wait List.*** The classes are held in Doherty Hall C316, and will be Tue, Thu 01:30-4:20 PM. By now, you should be subscribed to our course mailing list: 10615-announce@cs.cmu.edu. You can contact the instructors by emailing: 10615-instructors@cs.cmu.edu	
Natural_LoseWeight SuperFood Endorsed by Oprah Winfrey, Free Trial 1 bottle, pay only \$5.95 for shipping mfw rik Spam [X] Jacquelyn Halley to nherlein, boc: thehorney, boc: anj show details 9:52 PM (1 hour ago) Reply ==== Natural WeightLOSS Solution ==== Vital Acai is a natural WeightLOSS product that Enables people to lose weight and cleansing their bodies faster than most other products on the market. Here are some of the benefits of Vital Acai that You might not be aware of. These benefits have helped people who have been using Vital Acai daily to Achieve goals and reach new heights in there dieting that they never thought they could. * Rapid WeightLOSS * Increased metabolism - BurnFat & calories easily! * Better Mood and Attitude * More Self Confidence * Cleanse and Detoxify Your Body * Much More Energy * BetterSexLife * A Natural Colon Cleanse	

人脸识别



Example training images
for each orientation



天气预报



股票市场预测



天气预报



Temperature

72° F

项目概述

- 目标：预测学生在期末考试中的成绩。
- 数据：收集学生的历史成绩、出勤率、作业提交情况等。

数据收集

- 收集学生**过去的**考试成绩、作业成绩、课堂参与度等。
- 收集学生的**背景信息**，如年龄、性别、之前的教育背景。

数据预处理

- **清洗数据**，处理缺失值和异常值。
- 进行特征工程，提取有助于预测的**有用特征**。

模型训练

- 使用**历史数据**训练多种监督学习模型，如决策树、随机森林、梯度提升机等。
- 调整模型参数以获得最佳性能。

模型评估

- 使用交叉验证和不同的**评估指标**（如准确率、F1 分数）来评估模型。


应用

- 将训练好的模型应用于当前学生，预测他们的成绩。
- 根据预测结果，教师可以**提前识别**可能需要额外帮助的学生。

反馈循环

- 收集模型预测结果和实际成绩之间的**差异**。
- 使用这些反馈来进一步训练和改进模型。


学生成绩预测是监督学习在教育领域的一个实际应用，它可以帮助教师更好地理解学生的学习进度，并提供及时的支持。



无监督学习在**没有标签或分类**的情况下，从数据中发现模式、结构。机器根据自身的能力进行学习，它决定输入和输出应该是什么 - 聚类 (clustering) 是一种无监督学习方法，即机器自行学习，“物以类聚，人以群分”。在聚类中，一个著名的算法是 k 均值聚类 (k-means clustering)。

图像的聚类

Clustering images



[Goldberger et al.]

项目背景

- 目标：分析学生在课堂上的**学习行为模式**。
- 数据：收集学生在课堂上的**多模态数据**，包括语音、图像和文本数据。

数据收集

- 收集数据包括：学生在课堂上的发言、位置移动、身体动作和使用技术的行为。
- 数据来源：智能课堂的监控系统、学生学习管理系统。

聚类分析

- 使用K-均值聚类算法对学生行为进行分类。
- 基于学生在课堂上的行为特征，发现不同的学习行为模式。

结果解释

- 识别出**积极参与型**、**被动接受型**和**低参与型**等不同的学生学习行为模式。
- 发现某些学生可能需要额外的学习**支持或激励**。
- 揭示学生学习行为的**潜在动机和偏好**。

应用

- 为教师提供数据支持，优化教学方法和课堂管理。
- 帮助识别需要额外支持的学生，提供个性化的学习资源。
- 为学校提供学生学习行为的科学分析，改善教学质量。


无监督学习在学生行为分析中的应用


- 发现学生学习行为模式，优化教学方法。
- 提供个性化学习资源，改善教学质量。

Machine Learning Algorithms *(sample)*

	<u>Unsupervised</u>	<u>Supervised</u>
<u>Continuous</u>	• Clustering & Dimensionality Reduction ◦ SVD ◦ PCA ◦ K-means	• Regression ◦ Linear ◦ Polynomial • Decision Trees • Random Forests
<u>Categorical</u>	• Association Analysis ◦ Apriori ◦ FP-Growth • Hidden Markov Model	• Classification ◦ KNN ◦ Trees ◦ Logistic Regression ◦ Naive-Bayes ◦ SVM

典型的机器学习过程





- ① 评估方式
- ② 教材和参考书
- ③ 引 言
 - 什么是机器学习?
 - 监督学习
 - 无监督学习
- ④ 机器学习的基本术语
- ⑤ 发展历程
- ⑥ 主要的学术会议和期刊
- ⑦ 机器学习算法对为人处事的启发

针对数据：

- **数据集**：数据集 D ，每条数据代表一个样本，
- **属性 (attribute)、特征 (feature)**：其中 x 称为该样本的属性或特征
- **标记/标签 (label)**： y 称为该样本的标签或标记（对于监督学习）
- **训练/学习**：通过一个算法从该数据集（称为训练集）中学习得到一个带参数的模型，称为“训练”或“学习”。
- **训练集**(training set) 和 **测试集**(test set)

针对任务：

- **分类 (Classification)**：离散值；二分类，多分类
- **回归 (Regression)**：连续值
- **聚类 (Clustering)**：无标记信息，对数据分组
- **降维 (Dimension Reduction)**：无标记信息，对数据降维

有无标记信息：

- 监督学习 (Supervised learning)：训练数据包含预期的正确输出，通过学习使得模型对新的数据能产生正确的输出
- 无监督学习 (Unsupervised learning)：仅提供了数据，需要从中挖掘相似的模式、结构或子空间等
- 半监督学习 (Semi-supervised learning)：介于前两者之间。在训练过程中同时使用带有标签的数据和未标记的数据
- 自监督学习 (Self supervised learning)：自学成才。无监督学习的特例，利用数据本身的结构或特征之间的关系来自动生成标签，然后将这些生成的标签用于训练模型

基本术语

- 样本空间和特征向量: 由所有可能属性构成的空间称为“样本空间”或“输入空间”。该空间中的一个点 x 对应一个高维向量, 也称为“特征向量”。属性的数目对应空间的维度。
- 独立同分布: 通常假设数据集中的样本是通过从某个分布 $\mathcal{P}$ 中独立采样而获得。即这些样本满足“独立同分布”(independent and identically distributed, 简记为 i.i.d.)。
- 泛化 (Generalization) 能力: 机器学习的目标是使得学到的模型能很好的适用于“新样本”, 而不仅仅是训练集合。模型适用于新样本的能力即泛化能力。一般而言训练样本越多越有可能通过学习获得强泛化能力的模型

假设空间

- 假设空间 (Hypothesis): 对于当前任务, 学习算法所考虑的**所有可能的假设**构成的空间称为假设空间 (Hypothesis), 即模型可以表示的所有可能的解。
- 目标: 在模型空间中搜索不违背训练集的假设

归纳偏好

- 假设空间中可能有多个与训练集一致的假设, 但他们对测试数据会预测出不同的结果
- 选取哪个假设作为学习模型?
- 学习过程中对某种类型假设的**偏好**称作归纳偏好

归纳偏好

- 归纳偏好可看作学习算法自身在一个可能很庞大的假设空间中对假设进行选择的启发式或“价值观”
- “奥卡姆剃刀” (Occam's razor) 是一种常用的、自然科学研究中最基本的原则，即“若有多个假设与观察一致，选**最简单**的那个”
- 若非必要，勿增实体
- 哪个假设更简单，有时并“不容易”回答

没有免费的午餐 (No Free Lunch, NFL) 定理

- 在考虑所有可能的问题和算法的情况下，所有算法的性能都是一样的，即**没有一种算法能在所有问题上都表现最好**
- 一个算法**A**如果在某些问题上**比**另一个算法**B** **好**，必然存在另一些问题，算法**B** **比 A 好**。不存在一种“放之四海而皆准”的最优算法
- 实际问题中，并非所有问题出现的可能性都相同。脱离具体问题，空谈“什么学习算法更好”毫无意义
- 我们需要具体情况具体分析，根据具体的问题特点和数据分布来选择**合适**的算法

概率近似正确 (Probably Approximately Correct, PAC) 定理

- Leslie Valiant, 2010 年图灵奖得主, 计算学习理论
- 核心思想: 学习算法能够以**高概率**在一个接近正确的程度上输出正确的假设 (模型)。即模型的输出大概率是**近似正确**的。
- 公式: $P(|f(x) - y| \leq \epsilon) \geq 1 - \delta$
- “近似”是在取值上, 只要和真实值的偏差小于一个足够小的值就认为是“近似正确”
- “大概率”是在概率上, 即只要“近似正确”的概率足够大就认为“概率近似正确”
- 该定理对理解和分析机器学习算法的性能具有重要意义, 并为许多机器学习算法的分析提供了基础

机器学习无处不在：

- 搜索引擎、Web 搜索、垃圾邮件过滤、自动商品推荐
- 图像识别、语音识别
- 动画生成、艺术画生成、图像恢复、虚拟视频
- 机器翻译、聊天机器人、图文大模型
- 自动驾驶、机器人控制、具身智能
- 医学数据分析、医学辅助诊断
- 市场行情预测、股市预测
- 天气预报、能源勘探、环境监测
- AI4Science: 人工智能与生物、化学、物理、材料科学等的交叉

机器学习发展的分支

- 深度学习 (Deep Learning, DL)
- 计算机视觉 (Computer Vision, CV)
- 自然语言处理 (Natural Language Processing, NLP)
- 强化学习 (Reinforcement Learning, RL)
- 数据挖掘 (Data Mining, DM)

机器学习加速发展的原因

- 更多的数据 (Big data)
- 更好的机器学习算法
- 更快的计算机
- 更丰富的开源软件

- ① 评估方式
- ② 教材和参考书
- ③ 引 言
 - 什么是机器学习?
 - 监督学习
 - 无监督学习
- ④ 机器学习的基本术语
- ⑤ 发展历程
- ⑥ 主要的学术会议和期刊
- ⑦ 机器学习算法对为人处事的启发

推理期：

- A. Newell 和 H. Simon 的“逻辑理论家” (Logic Theorist) 程序以及此后的“通用问题求解” (General Problem Solving) 程序等在当时取得了令人振奋的结果。


知识期：

- 大量专家系统问世，在很多应用领域取得大量成果
- 但是由人来总结知识再教给计算机相当困难

学习期:

- 符号主义学习
 - -- 决策树: 以信息论为基础, 最小化信息熵, 模拟了人类对概念进行判定的树形流程
 - -- 基于逻辑的学习: 使用一阶逻辑进行知识表示, 通过修改扩充逻辑表达式对数据进行归纳
- 连接主义学习
 - -- 神经网络
 - -- 深度学习
- 统计学习
 - -- 支持向量机及核方法
- 深度学习
 - -- 卷积神经网络
 - -- Transformer
 - -- 大语言模型 LLM

发展历程



人工智能发展早期的三个代表性事件：

- 第一个从“经验”中学习的程序是 1959 年由 Arthur Samuel 设计的一种西洋跳棋 (Checker) 程序。该程序主要是基于 minimax 策略，即每一步操作均最大化自身的价值，并假设对手也从对方的角度最大化其价值。它包含了多个简单的学习算法来改进对当前棋面的评估。该程序通过自我学习，在模拟西洋跳棋的过程中变得越来越强。
- 1957 年，康奈尔大学的 Frank Rosenblatt 提出了感知机 (Perceptron) 模型。这是人工神经网络和现代深度学习的早期雏形。
- 1969 年，Marvin Minsky 和 Seymour Papert 指出，感知机模型不能解决简单的异或 (XOR) 操作，使人工智能的发展进入了冬天。

发展历程

(1) 1952 AI landmark: Samuel Checkers-playing Program-IBM

Herbert A. Simon



Allen Newell





Logical Theory

Principia Mathematica

(2) perceptron (1957)



Frank Rosenblatt
(1918-1970)



(3) MLP (1969) Minsky & Papert (1969)



AI winter: AI-logic(Top Down)→

ML: bottom up/Statistical optimization

(6) Nowadays

Deep learning, Knowledge base, reinforcement learning

(5) Enforcement learning(1994) Deep Blue



(4) Edward Albert Feigenbaum(1970)



father of expert systems



2018 年图灵奖得主



1. 约书亚·本吉奥 (Yoshua Bengio)：加拿大蒙特利尔大学计算机科学与运筹学系教授、加拿大人工智能研究所 (Mila) 主任。深度学习的先驱之一，与其他研究人员共同开创了深度学习领域的许多关键概念和技术
2. 杰弗里·欣顿 (Geoffery Hinton)：谷歌公司副总裁、工程研究员，多伦多人工智能矢量研究所首席科学顾问、多伦多大学名誉教授。被誉为“深度学习之父”。在人工智能领域有着非常重要的贡献，尤其是在神经网络和深度学习方面。是反向传播算法的先驱之一。
3. 杨立昆 (Yann LeCun)：纽约大学计算机科学系教授、Facebook 公司人工智能首席科学家。是卷积神经网络 (CNN) 的主要发明者之一，还是反向传播算法在神经网络中应用的先驱之一。

- ① 评估方式
- ② 教材和参考书
- ③ 引 言
 - 什么是机器学习?
 - 监督学习
 - 无监督学习
- ④ 机器学习的基本术语
- ⑤ 发展历程
- ⑥ 主要的学术会议和期刊
- ⑦ 机器学习算法对为人处事的启发

主要的学术会议

- 国际机器学习会议 (ICML)
- 国际神经信息处理系统会议 (NeurIPS)
- 国际学习理论会议 (COLT)
- 国际学习表征会议 (ICLR)
- 重要的区域性会议：欧洲机器学习会议 (ECML) 和亚洲机器学习会议 (ACML)

主要的学术期刊

- Journal of Machine Learning Research (JMLR)
- Machine Learning
- Artificial Intelligence
- IEEE Trans on Pattern Analysis and Machine Intelligence (TPAMI)
- IEEE Transactions on Neural Networks and Learning Systems (TNNLS)

- ① 评估方式
- ② 教材和参考书
- ③ 引 言
 - 什么是机器学习?
 - 监督学习
 - 无监督学习
- ④ 机器学习的基本术语
- ⑤ 发展历程
- ⑥ 主要的学术会议和期刊
- ⑦ 机器学习算法对为人处事的启发

k 近邻算法 (k-NN)

- 一种基于邻近度的分类算法。
- 通过测量不同特征值之间的距离来进行分类。

“近朱者赤近墨者黑”

哲学道理：“近朱者赤近墨者黑”

- 类似于 k -NN 的分类思想，**环境**对人的影响。
- 强调**个体**与**周围环境**的相似性。
- 在 k -NN 中，一个点的类别由其**最近的** k 个邻居决定。

团结与协作

- k-NN 算法中的“邻居”概念体现了**集体**的重要性。
- 一个样本的类别不是独立决定的，而是由其**周围的样本**共同决定。
- 类似于人类社会中的**团结与协作**精神，共同完成任务。

集体精神

- 在 k -NN 中，每个样本点都对分类结果有影响，体现了集体的力量。
- 没有单个样本的绝对权威，决策是**基于群体**的共识。

k 近邻算法不仅仅是一个分类工具，它还体现了深刻的哲学道理。

- “近朱者赤近墨者黑”：环境对个体的影响。
- 团结与协作：集体精神的重要性。

这是一个最好的时代，也是一个最坏的时代
这是一个内卷的时代，也是一个充满机遇的时代

The End