

LN7. 逻辑回归 (Logistic Regression)

张晓今

计算机学院数据挖掘与机器学习实验室

华中科技大学 Hopcroft 计算科学研究中心



- 1 介绍
 - 基本思想
 - 逻辑回归的 MLE
 - 逻辑回归的 MAP
 - 小结
- 2 更多讨论
 - sigmoid 函数
 - 损失函数
 - 正则化
 - 权重学习
- 3 逻辑回归 vs. 朴素贝叶斯
 - 比较

1 介绍


- 基本思想
- 逻辑回归的 MLE
- 逻辑回归的 MAP
- 小结

2 更多讨论

- sigmoid 函数
- 损失函数
- 正则化
- 权重学习

3 逻辑回归 vs. 朴素贝叶斯

- 比较



图：逻辑回归模型分类示例

- 逻辑回归是用于分类任务的经典机器学习算法。
- 如图所示，将数据输入到模型中，然后模型给出它的分类结果。

- 逻辑回归是**高斯朴素贝叶斯** (连续特征的朴素贝叶斯) 的判别形式
- 机器学习算法可以大致分为两类:
 - a) **生成算法**: 估计 $P(x_i, y)$ (通常分别对 $P(x_i|y)$ 和 $P(y)$ 建模)
 - b) **判别算法**: 判别模型 $P(y|x_i)$
- 朴素贝叶斯算法是生成算法。它对 $P(x_i|y)$ 建模, 并对其分布 (例如, 分类、多项、高斯、……) 作了明确的假设。该分布的参数可以用 MLE 或 MAP 来估计。

回顾:

1) 贝叶斯公式:

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)}$$

2) 贝叶斯分类器:

$$\operatorname{argmax}_y [p(y) \prod_{i=1}^n p(x_i|y, \theta)] = \operatorname{argmax}_y [\log(p(y)) + \sum_{i=1}^n \log(p(x_i|y, \theta))]$$


基本思想

- 上一讲曾给出，对于高斯朴素贝叶斯：

$$P(y|x_i) = \frac{1}{1 + e^{-y(w^T x_i + b)}}, y \in \{+1, -1\},$$

其中向量 w 和 b 是通过 $P(x_i|y)$ 的选择来唯一确定的。

- 逻辑回归通常被称为朴素贝叶斯对应的判别式模型。这里我们为 $P(y|x_i)$ 建模，并假设它完全符合形式： $P(y|x_i) = \frac{1}{1 + e^{-y(w^T x_i + b)}}$
- logistic(或 sigmoid 函数):



- 我们可以对 $P(x_i|y)$ 作假设。例如，它可以是高斯分布或多项分布。但这并不重要，因为我们直接用 MLE 或 MAP 估计向量 w 和 b ，以最大化 $\prod_i P(y_i|x_i; w, b)$ 的条件似然。
- 我们通过一个额外的常数维度（类似于感知机）将参数 b 吸收到 w 中。

$$P(y|X) = \frac{1}{1 + e^{-y(w^T X)}}$$

逻辑回归的 MLE

- 在 MLE 中, 我们选择**最大化条件似然**的参数。条件似然 $P(Y|X, w)$ 是以训练数据中特征向量 x_i 为条件的观测值 $Y \in R^n$ 中的概率。其中, $X = [x_1, \dots, x_i, \dots, x_n] \in R^{d \times n}$ 。
- 我们选择使该函数最大化的参数, 并假设对于给定的输入特征 x_i 和 w 时 y_i 之间是独立的。

$$P(y | X, w) = \prod_{i=1}^n P(y_i | x_i, w).$$

我们对上式取 $\log$:

$$\begin{aligned} \log \left(\prod_{i=1}^n P(y_i | x_i, w) \right) &= - \sum_{i=1}^n \log(1 + e^{-y_i w^T x_i}) \\ \hat{w}_{MLE} &= \operatorname{argmax}_w - \sum_{i=1}^n \log(1 + e^{-y_i w^T x_i}) \\ &= \operatorname{argmin}_w \sum_{i=1}^n \log(1 + e^{-y_i w^T x_i}) \end{aligned}$$

$$\hat{\mathbf{w}}_{MLE} = \underset{\mathbf{w}}{\operatorname{argmin}} \sum_{i=1}^n \log(1 + e^{-y_i \mathbf{w}^T \mathbf{x}_i})$$

- 我们需要估计参数 w 。为了求出最小值对应的参数，可以试着求出 $\nabla_w \sum_i^n \log(1 + e^{y_i w^T x_i}) = 0$ 。
- 该方程没有闭式解。我们在负对数似然上使用梯度下降来寻找近似解：

$$\ell(\mathbf{w}) = \sum_{i=1}^n \log(1 + e^{-y_i \mathbf{w}^T \mathbf{x}_i})$$

一维举例

考虑一个一维的情形，正类标记为加号，负类标记为圆。




图: (a) 数据集：纵轴为常数特征 $x_0 = 1$ (b) 对数似然。

这个对数似然函数如右所示，在两个参数的空间中 (w_0, w_1) ，最大值为 $(w_0 = 1, w_1 = 0.7)$ 。

一维情形





图: (a) 上页数据集的对数似然热图 (b) MLE 的解

下面是每个训练集中的样例对上述目标的贡献图:



二维情形

考虑一个二维的情形，正类标记为加号，负类标记为圆。




图: (a) 数据集 (b) Log 似然函数 (w_1, w_2) 在 $(-0.81, 0.81)$ 处取得最大值

二维情形




图: MLE 的解。其中红色表示正类的高概率。黑线表示 MLE 学到的决策边界

线性决策边界。为什么边界是线性的？考虑边界处的条件:

$$P(Y = 1|\mathbf{x}, \mathbf{w}) = P(Y = -1|\mathbf{x}, \mathbf{w}) \rightarrow \frac{1}{1+\exp\{-\mathbf{w}^\top \mathbf{x}\}} = \frac{\exp\{-\mathbf{w}^\top \mathbf{x}\}}{1+\exp\{-\mathbf{w}^\top \mathbf{x}\}} \rightarrow \mathbf{w}^\top \mathbf{x} = 0$$

对于上面的简单问题，最优 $\mathbf{w} = (-0.81, 0.81)$ ，求解

$$\mathbf{w}^\top \mathbf{x} = 0.81x_1 + 0.81x_2 = 0 \quad x_1 = x_2$$

逻辑回归的 MAP

- 在 MAP 估计中，我们将 w 作为一个随机变量，并可以指定它的先验分布。假设先验为： $w \sim N(0, \sigma^2 I)$ 。这是逻辑回归的高斯近似。
- 我们在 MAP 中的目标是找到对给定数据的**最大化后验**的模型参数。

$$P(w|D) = \frac{P(D|w)P(w)}{P(D)} \propto P(D|w)P(w)$$

$$\begin{aligned} P(w|D) &= P(w|X, y) \propto P(X, y|w)P(w) \\ &= P(y|X, w)P(X|w)P(w) \propto P(y|X, w)P(w) \end{aligned}$$

$$\begin{aligned} \hat{w}_{MAP} &= \underset{w}{\operatorname{argmax}} \log(P(y|X, w)P(w)) \\ &= \underset{w}{\operatorname{argmin}} \sum_{i=1}^n \log(1 + e^{y_i w^T x_i}) + \lambda w^T w \end{aligned}$$

$\lambda = \frac{1}{2\sigma^2}$ 。同样，这个函数没有闭式解，但我们可以在负对数后验上使用梯度下降来找到最优的参数。

$$\ell(w) = \sum_{i=1}^n \log(1 + e^{-y_i w^T x_i}) + \lambda w^T w$$

- 逻辑回归是朴素贝叶斯对应的判别模型。
- 在朴素贝叶斯中，我们首先为每个标签 y 建模 $P(x|y)$ ，然后获得最能区分这两个分布的决策边界。
- 在逻辑回归中，不对数据分布 $P(x|y)$ 建模，而是直接对 $P(y|x)$ 建模。
- 假设满足 $P(y|x_i) = \frac{1}{1 + e^{y(w^T x_i + b)}}$ ，但并没有以任何方式限制对 $P(x|y)$ 的假设（实际上它可以是指数函数）。
- 这使得逻辑回归更加灵活，但这种灵活性也需要更多的数据来避免出现过拟合现象。
- 通常，在数据很少且建模假设是合适的情况下，朴素贝叶斯一般要优于逻辑回归。然而，随着数据集变得越来越大，逻辑回归的表现往往优于朴素贝叶斯，这是因为对 $P(x|y)$ 所做的假设可能并不完全正确。
- 如果假设完全正确，即数据来自我们在朴素贝叶斯中假设的分布，那么逻辑回归和朴素贝叶斯在极限上可收敛到完全相同的结果（但朴素贝叶斯会更快）。

两种方法之间的区别:

Model	Naive Bayes	Logistic Regression
Assumption	$P(\mathbf{X} Y)$ is simple	$P(Y \mathbf{X})$ is simple
Likelihood	Joint	Conditional
Objective	$\sum_i \log P(y_i, \mathbf{x}_i)$	$\sum_i \log P(y_i \mathbf{x}_i)$
Estimation	Closed Form	Iterative (gradient, etc)
Decision Boundary	Quadratic/Linear (see below)	Linear
When to use	Very little data vs parameters	Enough data vs parameters

1 介绍

- 基本思想
- 逻辑回归的 MLE
- 逻辑回归的 MAP
- 小结

2 更多讨论

- sigmoid 函数
- 损失函数
- 正则化
- 权重学习

3 逻辑回归 vs. 朴素贝叶斯

- 比较

基本思想

- $f(z) = h_{\theta}(x) = \text{sigmoid}(z) = \frac{1}{1+e^{-z}}$
- 输出 = 0 或 1
- Hypothesis $\rightarrow z = w^T x + b$

我们通常把 sigmoid 函数放在模型的最后，它将输出概率约束在 $[0,1]$ 。




图: 如果 $t \rightarrow \infty$, $y(\text{预测})$ 将为 1, 如果 $t \rightarrow -\infty$, $y(\text{预测})$ 将为 0。

损失函数

预测概率:

$$P(y = 1|x) = h_{\theta}(x) = \frac{1}{1 + e^{(-\theta^T x)}} = \sigma(\theta^T x) \quad (1)$$

$$P(y = 0|x) = 1 - P(y = 1|x) = 1 - h_{\theta}(x) \quad (2)$$

结合 (1) 和 (2):

$$P(y|x; \theta) = (h_{\theta}(x))^y (1 - h_{\theta}(x))^{1-y} \quad \text{y 表示标签, 取值为 0 或 1} \quad (3)$$

对给定的 m 个样本, 使用最大似然估计 (MLE):

$$L(\theta) = \prod_{i=1}^m P(y^{(i)}|x^{(i)}; \theta) = \prod_{i=1}^m (h_{\theta}(x^{(i)}))^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{1-y^{(i)}} \quad (6)$$

$$\rightarrow \ell(\theta) = \log L(\theta) = \sum_{i=1}^m (y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))) \quad (7)$$

$$J(\theta) = -\frac{1}{m} \ell(\theta)$$

$J(\theta)$ 是设计的损失函数


基本思想

- L_2 正则:

$$J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h_{\theta}(x^{(i)}))^2 + \lambda \sum_{j=1}^n \theta_j^2 \right] \quad (8)$$

- 正则化: 防止权重变得过大
- 正则化可以通过对权值的约束在一定程度上避免过拟合


Example: Logistic regression




$$\rightarrow h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

(g = sigmoid function)

“Underfit”



$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2 + \theta_5 x_1 x_2)$$




$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_1^2 + \theta_3 x_1^2 x_2 + \theta_4 x_1^2 x_2^2 + \theta_5 x_1^2 x_2^3 + \theta_6 x_1^3 x_2 + \dots)$$


“Overfit”

图：欠拟合/过拟合


通过逻辑回归对任务进行分类



$\lambda = 1$ Good !





$\lambda = 0$ Overfitting



$\lambda = 100$ Underfitting

图: 不同 λ 值的二分类效果

梯度下降



$$J(\theta) = - \sum_{i=1}^m (y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_{\theta}(y^{(i)}))) \quad (9)$$

↓

偏导数:

$$\frac{\partial J(\theta)}{\partial \theta_j} = \sum_i x_j^{(i)} (h_{\theta}(x^{(i)}) - y^{(i)})$$

↓

权重更新:

$$\theta_j = \theta_j - \alpha \frac{\partial J(\theta)}{\partial \theta_j}$$

- 1 介绍
 - 基本思想
 - 逻辑回归的 MLE
 - 逻辑回归的 MAP
 - 小结
- 2 更多讨论
 - sigmoid 函数
 - 损失函数
 - 正则化
 - 权重学习
- 3 逻辑回归 vs. 朴素贝叶斯
 - 比较

生成式 vs. 判别式

- 机器学习算法可以大致分为两类:
- 生成算法, 估计 $P(x_i, y)$ (通常分别对 $P(x_i|y)$ 和 $P(y)$ 建模)。
- 判别算法, 使用模型 $P(y|x_i)$ 来生成 x_i 的预测输出。

- 朴素贝叶斯算法是生成算法 ($p(y), p(x|y) \rightarrow p(y|x)$)

$$P(y|x) = \frac{p(x, y)}{\prod_y p(x, y)} = \frac{p(y)p(x|y)}{\prod_y p(y)p(x|y)}$$

- 逻辑回归算法是判别算法 (梯度下降 $\rightarrow w$)

$$P(y|x_i) = \frac{1}{1 + e^{-y(w^T x_i + b)}}$$

The End