

LN10. 线性支持向量机 (SVM)

何 琨

计算机学院数据挖掘与机器学习实验室

华中科技大学 Hopcroft 计算科学研究中心

邮箱: brooklet60@hust.edu.cn

2026 月 4 月



- ① 概述
 - 支持向量机 (SVM)
- ② 线性支持向量机
 - 间隔
 - 最大间隔分类器
 - 支持向量
 - SVM 示例
- ③ 带软约束的 SVM
 - 软约束 SVM 概述
 - 无约束假设
 - 软间隔 SVM 实例
- ④ SVM 总结

- 1 概述
 - 支持向量机 (SVM)
- 2 线性支持向量机
 - 间隔
 - 最大间隔分类器
 - 支持向量
 - SVM 示例
- 3 带软约束的 SVM
 - 软约束 SVM 概述
 - 无约束假设
 - 软间隔 SVM 实例
- 4 SVM 总结

基本思想:

支持向量机 (Support Vector Machine, SVM) 是一种线性分类器, 可以被视为感知机的扩展。如果数据线性可分, 感知器可保证找到某个超平面, SVM 则找到具有最大间隔的分离超平面。




图: 同一数据集两个不同的分离超平面




图: 最大间隔超平面

定义:

- 数据集: $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$
- 二元分类标签: $y_i \in \{-1, +1\}, i = 1, \dots, N$
- 线性分类器: $h(x) = \text{sign}(w^T x + b)$




图: 同一个数据集有许多分离超平面

关于感知机的回顾: 如果数据是线性可分的, 我们可以通过感知机找到许多不同的超平面。

问题: 什么是最好的分离超平面?




图: 最大间隔 (Margin) 超平面

SVM 的回答: 最大化两类数据到超平面的最小距离, 即具有**最大间隔**的超平面。

如上图所示, 间隔 γ 是从超平面 (实线) 到两个类中最近的点 (平行虚线) 的距离。

如果超平面是使 γ 最大的, 它必然位于两个类的正中间 (思考: 为什么)。

- ① 概述
 - 支持向量机 (SVM)
- ② 线性支持向量机
 - 间隔
 - 最大间隔分类器
 - 支持向量
 - SVM 示例
- ③ 带软约束的 SVM
 - 软约束 SVM 概述
 - 无约束假设
 - 软间隔 SVM 实例
- ④ SVM 总结

间隔 (Margin):

- 超平面: $H = \{ \mathbf{x} | \mathbf{w}^T \mathbf{x} + \mathbf{b} = 0 \}$
- 从超平面到两类中最近点的距离: γ

间隔 (Margin):

考虑某个点 $\mathbf{x}$ 。设 $\mathbf{d}$ 为从超平面 H 到 $\mathbf{x}$ 的具有最小长度的向量。设 $\mathbf{x}^P$ 为 $\mathbf{x}$ 在 H 上的投影。则有:

$$\mathbf{x}^P = \mathbf{x} - \mathbf{d}$$


$\mathbf{d}$ 平行于 $\mathbf{w}$, 因此 $\mathbf{d} = \alpha \mathbf{w}$, $\alpha \in \mathbb{R}$ 。

由 $\mathbf{x}^P \in H$ 可知, $\mathbf{w}^T \mathbf{x}^P + b = 0$

所以

$$\mathbf{w}^T \mathbf{x}^P + b = \mathbf{w}^T (\mathbf{x} - \mathbf{d}) + b = \mathbf{w}^T (\mathbf{x} - \alpha \mathbf{w}) + b = 0$$

推导得到: $\alpha = \frac{\mathbf{w}^T \mathbf{x} + b}{\mathbf{w}^T \mathbf{w}}$



间隔 (Margin):

由上页, 我们得出 $\alpha = \frac{\mathbf{w}^T \mathbf{x} + b}{\mathbf{w}^T \mathbf{w}}$, $\mathbf{d} = \alpha \mathbf{w}$

$\mathbf{d}$ 的模长:



$$\|\mathbf{d}\|_2 = \sqrt{\mathbf{d}^T \mathbf{d}} = \alpha \sqrt{\mathbf{w}^T \mathbf{w}} = \frac{|\mathbf{w}^T \mathbf{x} + b|}{\sqrt{\mathbf{w}^T \mathbf{w}}} = \frac{|\mathbf{w}^T \mathbf{x} + b|}{\|\mathbf{w}\|_2}$$

$\mathcal{H}$ 相对于 $\mathcal{D}$ 的间隔距离:

$$\gamma(\mathbf{w}, b) = \min_{\mathbf{x} \in \mathcal{D}} \frac{|\mathbf{w}^T \mathbf{x} + b|}{\|\mathbf{w}\|_2}$$

根据定义, 间隔相对于超平面具有伸缩不变性, 即:

$$\gamma(\beta \mathbf{w}, \beta b) = \gamma(\mathbf{w}, b), \forall \beta \neq 0$$



可以将我们对于最大间隔分离超平面的搜索，表述为一个约束优化问题。目标是在所有数据点必须位于超平面正确一侧的约束下，使间隔最大化：

$$\underbrace{\max_{\mathbf{w}, b} \gamma(\mathbf{w}, b)}_{\text{maximize margin}} \quad s.t. \quad \underbrace{\forall i \, y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 0}_{\text{separating hyperplane}}$$

如果添加 γ 的定义，我们得到：

$$\underbrace{\max_{\mathbf{w}, b} \underbrace{\frac{1}{\|\mathbf{w}\|_2} \min_{\mathbf{x}_i \in D} |\mathbf{w}^T \mathbf{x}_i + b|}_{\gamma(\mathbf{w}, b)}}_{\text{maximize margin}} \quad s.t. \quad \underbrace{\forall i \, y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 0}_{\text{separating hyperplane}}$$

最大间隔分类器

$$\underbrace{\max_{\mathbf{w}, b} \underbrace{\frac{1}{\|\mathbf{w}\|_2} \min_{x_i \in D} |\mathbf{w}^T \mathbf{x}_i + b|}_{\gamma(\mathbf{w}, b)}}_{\text{maximize margin}} \quad s.t. \quad \underbrace{\forall i \ y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 0}_{\text{separating hyperplane}}$$

由于超平面具有伸缩不变性: $\gamma(\beta \mathbf{w}, \beta b) = \gamma(\mathbf{w}, b), \forall \beta \neq 0$, 我们可以固定 $\mathbf{w}, b$ 的伸缩程度, 可以这样选择:

$$\min_{\mathbf{x} \in D} |\mathbf{w}^T \mathbf{x} + b| = 1.$$

我们可以将这种重新缩放作为等式约束。那么我们的目标就是:

$$\max_{\mathbf{w}, b} \frac{1}{\|\mathbf{w}\|_2} \cdot 1 = \min_{\mathbf{w}, b} \|\mathbf{w}\|_2 = \min_{\mathbf{w}, b} \mathbf{w}^T \mathbf{w}$$

从上面的目标我们知道这是一个凸二次函数。

最大间隔分类器

由上面讨论，新的优化问题为：


$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \mathbf{w}^\top \mathbf{w} \\ \text{s.t.} \quad & \forall i, y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 0, \\ & \min_i |\mathbf{w}^\top \mathbf{x}_i + b| = 1 \end{aligned}$$

然后，可以合并约束条件得到一个更简单的公式：

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \mathbf{w}^\top \mathbf{w} \\ \text{s.t.} \quad & \forall i, y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 \end{aligned}$$

这个新公式是一个二次优化问题。目标是二次的，约束条件都是线性的。可以用 QCQP (Quadratic Constrained Quadratic Program) 求解器来有效地求解，得到唯一解。

基于超平面的伸缩不变性，可以找到最简单的超平面（其中更简单意味着更小的 $\mathbf{w}^\top \mathbf{w}$ ），这样所有输入数据在超平面的正确一侧，且距离超平面至少 1 个单位。



由于超平面具有缩放不变性，我们可以重新缩放 w , b ，使所有点到它的距离至少为 1 个单位。因此，对于最优的 w, b 对，一些训练点将有严格的约束，即：

$$y_i(w^T x_i + b) = 1.$$

上图中可以清楚地看到这些蓝色的点，恰位于虚线上。我们将这些训练数据点称为**支持向量**。支持向量是特殊的点，因为它们是定义超平面到数据集最大间隔的训练点，决定了超平面的形状。如果移动其中一个并重新训练 SVM，生成的超平面将会改变。

SVM 示例:




图: Training result




图: Test result

[SVM code click here](#)

- 1 概述
 - 支持向量机 (SVM)
- 2 线性支持向量机
 - 间隔
 - 最大间隔分类器
 - 支持向量
 - SVM 示例
- 3 带软约束的 SVM
 - 软约束 SVM 概述
 - 无约束假设
 - 软间隔 SVM 实例
- 4 SVM 总结

软约束 SVM 概述:

如果是低维数据或数据中有噪声, 通常情况下, 这两类数据间没有可分离的超平面。




图: 非线性可分

例如, 上图中, 红色的点可能是噪声点或点的标签是错误的, 显然, 此优化问题没有解。

软约束 SVM 概述:




图: 可能包含噪音

另一种情形如上图。可以找到线性可分离超平面 (实线)。但是这个超平面的间隔太小了。因此, 我们可能会认为红点是噪音或其标签是错误的。

如果不考虑红点, 可能会找到另一个更好的超平面 (虚线), 这估计也是最好的超平面。

未匹配计数损失 (misMatched Count Loss)

对于上面讨论的情况，可以忽略这些不匹配的噪声点，并将它们视为损失。

计算不匹配点的数量，并将它们添加到目标中，可得：

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^n [y_i \neq \text{sign}(\mathbf{w}^T \mathbf{x}_i + b)] \\ \text{s.t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad \text{if } y_i \text{ is correct} \\ & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq -\infty, \quad \text{if } y_i \text{ is incorrect} \end{aligned} \quad (1)$$

在约束 (1) 中，如果 y_i 是不正确的，我们不对噪声点添加任何约束。

在上面的目标中， C 是用于大间隔和噪声容忍的权衡

无约束假设:

在上一页中, 我们定义了未匹配计数损失 $[\cdot]$ 来计算错误匹配的数量。然而, 它是非线性和不连续的。这对计算很不方便。因此, 使用线性约束松弛变量 ξ_i 来记录间隔违反的程度而非不匹配的计数:

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^n \xi_i \\ \text{s.t.} \quad & \forall i \ y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \forall i \ \xi_i \geq 0 \end{aligned}$$

松弛变量 ξ_i 允许输入 $\mathbf{x}_i$ 更接近超平面 (甚至在错误的一侧), 但在目标函数中对这种“松弛”有惩罚。

- 如果 C 非常大, SVM 会变得非常严格, 并试图让所有点都在超平面正确的一侧。
- 如果 C 非常小, SVM 会变得非常松散, 可能会“牺牲”一些点来获得一个更简单的解 (即更低的 $\|\mathbf{w}\|_2^2$)。

无约束假设:

Loss ξ_i

让我们考虑在 $C \neq 0$ 的情况下 ξ_i 的值。可以考虑 ξ_i 作为损失，目标总是尽可能地最小化 ξ_i ，则有：

$$\xi_i = \begin{cases} 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b), & \text{if } y_i(\mathbf{w}^T \mathbf{x}_i + b) < 1 \\ 0, & \text{if } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1. \end{cases} \quad (2)$$

这等价于下面的形式：

$$\xi_i = \max(1 - y_i(\mathbf{w}^T \mathbf{x}_i + b), 0).$$

无约束假设

如果将这个形式加入到 SVM 优化问题的目标中，可得到如下无约束版本，作为损失函数和正则项：

$$\min_{\mathbf{w}, b} \underbrace{\mathbf{w}^T \mathbf{w}}_{l_2\text{-regularizer}} + C \sum_{i=1}^n \underbrace{\max [1 - y_i(\mathbf{w}^T \mathbf{x} + b), 0]}_{\text{hinge-loss}}$$

该公式允许我们优化 SVM 的参数 $(\mathbf{w}, b)$ ，就像逻辑回归（例如通过梯度下降）一样。唯一的区别是我们用的是 **hinge-loss** 而不是 **logistic loss**。

软间隔 SVM 的实例




图: train : $C = 0.01$




图: train : $C = 0.1$




图: train : $C = 1$




图: test : $C = 0.01$




图: test : $C = 0.1$




图: test : $C = 1$

软间隔 SVM 实例




图: train : $C = 10$




图: train : $C = 100$




图: test : $C = 10$




图: test : $C = 100$

从上面的示例图中，可以看到不同的 C 可能得到不同的分离超平面。如果 C 非常大，SVM 会变得非常严格，并试图让所有点都在超平面的正确的一侧。但这可能会导致过拟合。

如果 C 非常小，SVM 就会变得非常松弛，可能会“牺牲”一些点来获得一个更简单的解决方案 (即更小的 $\|\mathbf{w}\|_2^2$)。

[Soft SVM code click here](#)

- ① 概述
 - 支持向量机 (SVM)
- ② 线性支持向量机
 - 间隔
 - 最大间隔分类器
 - 支持向量
 - SVM 示例
- ③ 带软约束的 SVM
 - 软约束 SVM 概述
 - 无约束假设
 - 软间隔 SVM 实例
- ④ SVM 总结

- 支持向量机 (SVM) 是一种线性分类器，可以被视为感知机的扩展。SVM 找到分离超平面的最大间隔。
- 间隔是超平面到两个类中最近点的距离。
- 最大间隔分类器是在所有数据点必须位于超平面正确一侧的约束下，使间隔最大化。
- 对于最优的 w, b 对，一些训练点将有严格的约束，即 $y_i(w^T x_i + b) = 1$ ，称为支持向量。
- 支持向量机是凸二次函数，可以用 QCQP 求解器求解。
- 在目标中加入松弛变量，可以得到无约束支持向量机公式：带软约束的支持向量机。

The End