

LN18. 集成方法: Bagging 和随机森林

何 琨

计算机学院数据挖掘与机器学习实验室

华中科技大学 Hopcroft 计算科学研究中心

邮箱: brooklet60@hust.edu.cn

2026 年 4 月



- 1 集成学习概述
- 2 Bagging 概述
- 3 Bias-Variance 分解
- 4 大数定律与方差降低
- 5 问题与解决方案
- 6 Bagging 的具体操作
- 7 Bagging 的优势
- 8 随机森林 (Random Forest)
- 9 随机森林的变体
- 10 实际应用案例
- 11 总结与展望

- 1 集成学习概述
- 2 Bagging 概述
- 3 Bias-Variance 分解
- 4 大数定律与方差降低
- 5 问题与解决方案
- 6 Bagging 的具体操作
- 7 Bagging 的优势
- 8 随机森林 (Random Forest)
- 9 随机森林的变体
- 10 实际应用案例
- 11 总结与展望

- **集成学习**：通过结合多个模型的预测来提高整体性能。
- **为什么需要集成学习**：
 - 单个模型可能存在过拟合或欠拟合问题。
 - 集成多个模型可以利用“智慧的群体”效应，减少误差。
- **常见的集成学习方法**：
 - Bagging (Bootstrap Aggregating)
 - Boosting (如 AdaBoost, Gradient Boosting)
 - Stacking

- 1 集成学习概述
- 2 Bagging 概述
- 3 Bias-Variance 分解
- 4 大数定律与方差降低
- 5 问题与解决方案
- 6 Bagging 的具体操作
- 7 Bagging 的优势
- 8 随机森林 (Random Forest)
- 9 随机森林的变体
- 10 实际应用案例
- 11 总结与展望

- **Bagging 的定义：**
Bagging 是一种集成学习方法，
通过从原始数据集中有放回地采样生成多个新的数据集，
然后在每个新数据集上训练一个模型，
最后将所有模型的预测结果进行平均或投票。
- **Bagging 的目标：**降低模型的方差，从而提高模型的泛化能力。
- **历史背景：**由 Leo Breiman 于 1996 年提出。

- 1 集成学习概述
- 2 Bagging 概述
- 3 Bias-Variance 分解
- 4 大数定律与方差降低
- 5 问题与解决方案
- 6 Bagging 的具体操作
- 7 Bagging 的优势
- 8 随机森林 (Random Forest)
- 9 随机森林的变体
- 10 实际应用案例
- 11 总结与展望

- 误差分解公式：

$$\underbrace{\mathbb{E}[(h_D(x) - y)^2]}_{\text{Error}} = \underbrace{\mathbb{E}[(h_D(x) - \bar{h}(x))^2]}_{\text{Variance}} + \underbrace{\mathbb{E}[(\bar{h}(x) - \bar{y}(x))^2]}_{\text{Bias}} + \underbrace{\mathbb{E}[(\bar{y}(x) - y(x))^2]}_{\text{Noise}}$$

- 解释：

- 方差 (Variance)：模型对训练数据的敏感程度。高方差模型容易过拟合。
- 偏差 (Bias)：模型预测值与真实值之间的差异。高偏差模型容易欠拟合。
- 噪声 (Noise)：数据本身的随机性，无法通过模型改进。

- Bagging 的作用：

主要降低方差，对方差高的模型（如决策树）效果显著。

- 1 集成学习概述
- 2 Bagging 概述
- 3 Bias-Variance 分解
- 4 大数定律与方差降低**
- 5 问题与解决方案
- 6 Bagging 的具体操作
- 7 Bagging 的优势
- 8 随机森林 (Random Forest)
- 9 随机森林的变体
- 10 实际应用案例
- 11 总结与展望

- 大数定律：

对于独立同分布的随机变量，当样本数量足够大时，样本均值会趋近于期望值。

- 应用到分类器：

- 假设我们有 m 个独立的训练集 $D_1, D_2, \dots, D_m$ 。
- 在每个训练集上训练一个分类器 h_{D_i} 。
- 最终分类器为所有分类器的平均结果： $\hat{h} = \frac{1}{m} \sum_{i=1}^m h_{D_i}$ 。
- 随着 m 的增大， $\hat{h}$ 会趋近于期望值 $\bar{h}$ ，从而方差项趋近于 0。

- 1 集成学习概述
- 2 Bagging 概述
- 3 Bias-Variance 分解
- 4 大数定律与方差降低
- 5 问题与解决方案**
- 6 Bagging 的具体操作
- 7 Bagging 的优势
- 8 随机森林 (Random Forest)
- 9 随机森林的变体
- 10 实际应用案例
- 11 总结与展望

- **问题：**在实际应用中，我们通常只有一个数据集 D ，而不是多个不同的训练集。
- **解决方案：**通过从数据集 D 中有放回地均匀采样来生成多个新的数据集。
 - **有放回采样：**每个样本被选中的概率相同，且每次采样后样本被放回，允许重复。
 - **生成的数据集：**每个新数据集的大小与原始数据集相同，但包含重复的样本。

- 1 集成学习概述
- 2 Bagging 概述
- 3 Bias-Variance 分解
- 4 大数定律与方差降低
- 5 问题与解决方案
- 6 Bagging 的具体操作**
- 7 Bagging 的优势
- 8 随机森林 (Random Forest)
- 9 随机森林的变体
- 10 实际应用案例
- 11 总结与展望

Bagging 的具体操作

• 步骤:

- ① 采样: 从原始数据集 D 中有放回地采样生成 m 个新的数据集 $D_1, D_2, \dots, D_m$ 。
- ② 训练: 在每个新数据集 D_j 上训练一个分类器 $h_j()$ 。
- ③ 集成: 将所有分类器的预测结果进行平均 (回归任务) 或投票 (分类任务)。

• 示例:

- 假设有 100 个样本, 生成 10 个新的数据集, 每个数据集包含 100 个样本 (有重复)。
- 在每个数据集上训练一个决策树, 最终分类器为所有决策树的平均结果。

- 1 集成学习概述
- 2 Bagging 概述
- 3 Bias-Variance 分解
- 4 大数定律与方差降低
- 5 问题与解决方案
- 6 Bagging 的具体操作
- 7 Bagging 的优势**
- 8 随机森林 (Random Forest)
- 9 随机森林的变体
- 10 实际应用案例
- 11 总结与展望

- **降低方差**：通过集成多个模型，减少对训练数据的敏感性，降低过拟合风险。
- **易于实现**：实现过程简单，只需采样和训练多个模型。
- **提供预测不确定性估计**：预测结果的平均值和方差可以作为不确定性的度量，在回归任务中尤其有用。
- **无偏的测试误差估计 (Out-of-Bag Error)**：
 - **Out-of-Bag (OOB) 样本**：每个训练点未被选中的数据集。
 - **OOB 误差估计**：利用 OOB 样本计算误差，无需额外的测试集。

- 1 集成学习概述
- 2 Bagging 概述
- 3 Bias-Variance 分解
- 4 大数定律与方差降低
- 5 问题与解决方案
- 6 Bagging 的具体操作
- 7 Bagging 的优势
- 8 随机森林 (Random Forest)**
- 9 随机森林的变体
- 10 实际应用案例
- 11 总结与展望

随机森林 (Random Forest)

- 简介：随机森林是最著名和实用的 Bagging 算法之一，本质上是带有修改后的分裂标准的 Bagging 决策树。
- 算法步骤：
 - ① 采样：从原始数据集 D 中有放回地采样生成 m 个新的数据集。
 - ② 特征选择：在每次分裂前，随机抽取 $k \leq d$ 个特征（无放回），仅考虑这些特征进行分裂。
 - ③ 训练：在每个新数据集上训练一个满决策树（不进行剪枝）。
 - ④ 集成：将所有决策树的预测结果进行平均（回归）或投票（分类）。
- 优势：
 - 超参数不敏感：通常选择 $k = \sqrt{d}$ (d 为特征数量)， m 取尽可能大的值。
 - 数据预处理要求低：适用于异构数据，无需特征缩放或标准化。

- 1 集成学习概述
- 2 Bagging 概述
- 3 Bias-Variance 分解
- 4 大数定律与方差降低
- 5 问题与解决方案
- 6 Bagging 的具体操作
- 7 Bagging 的优势
- 8 随机森林 (Random Forest)
- 9 随机森林的变体**
- 10 实际应用案例
- 11 总结与展望

- **分区训练与标签估计：**

- 将每个训练集分为两部分，一部分用于构建树，另一部分用于估计叶标签。
- 当叶节点在标签估计部分中只有一个点时停止分裂，这样可以使树和随机森林分类器具有一致性。

- **基于留出样本的剪枝：**

- 不将树生长到满深度，而是根据留出样本来剪枝。
- 通过调整剪枝参数，进一步改善偏差/方差权衡。

- 1 集成学习概述
- 2 Bagging 概述
- 3 Bias-Variance 分解
- 4 大数定律与方差降低
- 5 问题与解决方案
- 6 Bagging 的具体操作
- 7 Bagging 的优势
- 8 随机森林 (Random Forest)
- 9 随机森林的变体
- 10 实际应用案例**
- 11 总结与展望

- **案例 1：房屋价格预测：**

- 使用随机森林回归模型预测房屋价格。
- 通过 OOB(Out of Bag) 误差估计模型的泛化能力。

- **案例 2：手写数字识别：**

- 使用随机森林分类模型识别手写数字。
- 比较不同超参数设置下的模型性能。

- 1 集成学习概述
- 2 Bagging 概述
- 3 Bias-Variance 分解
- 4 大数定律与方差降低
- 5 问题与解决方案
- 6 Bagging 的具体操作
- 7 Bagging 的优势
- 8 随机森林 (Random Forest)
- 9 随机森林的变体
- 10 实际应用案例
- 11 总结与展望**

- 总结:

- Bagging 是一种有效的集成学习方法，通过降低方差提高模型性能。
- 随机森林作为 Bagging 的经典应用，在实际问题中表现出色且易于使用。

- 展望:

- 探索其他集成学习方法（如 Boosting）。
- 结合实际问题，选择合适的集成学习算法及其变体。

The End