

LN20. 高斯过程

何 琨

计算机学院数据挖掘与机器学习实验室

华中科技大学 Hopcroft 计算科学研究中心

邮箱: brooklet60@hust.edu.cn

2026 年 4 月



- ① 多元高斯分布的性质
 - 一旦高斯，永远高斯
- ② 高斯过程回归
- ③ 高斯过程的定义
- ④ 高斯过程回归 (GPR)
- ⑤ 加性高斯噪声
- ⑥ 高斯过程实践
- ⑦ 总结
- ⑧ 应用：贝叶斯全局优化

- 1 多元高斯分布的性质
 - 一旦高斯，永远高斯
- 2 高斯过程回归
- 3 高斯过程的定义
- 4 高斯过程回归 (GPR)
- 5 加性高斯噪声
- 6 高斯过程实践
- 7 总结
- 8 应用：贝叶斯全局优化

回顾高斯分布的定义和性质

一个高斯随机变量 $X \sim \mathcal{N}(\mu, \Sigma)$, 其中 μ 是均值, Σ 是协方差矩阵, 其概率密度函数为


$$P(x; \mu, \Sigma) = \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|} e^{-\frac{1}{2} ((x-\mu)^\top \Sigma^{-1} (x-\mu))}$$

其中 $|\Sigma|$ 是协方差矩阵 Σ 的行列式。

高斯分布是现实世界的数据中经常出现的一种分布。这是由于中央极限定理 (CLT) 的保证。

中央极限定理表明, 无论原始样本的分布如何, 只要它具有有限的均值和方差, 则 $m > 0$ 个样本的算术平均值近似服从正态分布。

中央极限定理



中央极限定理示例： 在上面的图表中，随机变量 Y 从条形图展示的分布中采样获得。上图中，值为 1、2 和 9、10 是可能的，但 3 到 8 的值没有支持。该分布看起来完全不是高斯分布。

然而，当样本均值 $\bar{Y}_j = \frac{1}{N} \sum_{i=1}^N y_i$ 被采样 m 次时，随着 m 的增加（下图），样本均值 $\bar{Y}_1, \dots, \bar{Y}_m$ 会越来越趋近“高斯”分布。

一旦高斯，永远高斯

设高斯随机变量 $y = \begin{bmatrix} y_A \\ y_B \end{bmatrix}$, , 均值 $\mu = \begin{bmatrix} \mu_A \\ \mu_B \end{bmatrix}$, 协方差矩阵 $\Sigma = \begin{bmatrix} \Sigma_{AA} & \Sigma_{AB} \\ \Sigma_{BA} & \Sigma_{BB} \end{bmatrix}$ 。我们有以下性质：

- 1. 归一化：

$$y_A \sim \mathcal{N}(\mu_A, \Sigma_{AA})$$

$$\int_y p(y; \mu, \Sigma) dy = 1 \quad (\text{当然成立!})$$

- 2. 边缘分布：边缘分布 $p(y_A) = \int_{y_B} p(y_A, y_B; \mu, \Sigma) dy_B$ 和 $p(y_B) = \int_{y_A} p(y_A, y_B; \mu, \Sigma) dy_A$ 是高斯分布：

$$y_A \sim \mathcal{N}(\mu_A, \Sigma_{AA}) \quad y_B \sim \mathcal{N}(\mu_B, \Sigma_{BB}).$$

- 3. 求和：两个高斯分布按比例求和得到的是高斯混合分布。

$$f(x) = p \cdot \frac{1}{\sqrt{2\pi}\sigma_1} \exp\left(-\frac{(x - \mu_1)^2}{2\sigma_1^2}\right) + (1 - p) \cdot \frac{1}{\sqrt{2\pi}\sigma_2} \exp\left(-\frac{(x - \mu_2)^2}{2\sigma_2^2}\right)$$

- 4. 条件分布：给定 y_B 时， y_A 的条件分布

$$p(y_A|y_B) = \frac{p(y_A, y_B; \mu, \Sigma)}{\int_{y_A} p(y_A, y_B; \mu, \Sigma) dy_A},$$

也是高斯分布：

举例：

假设我们调查了 100 个人（含男生和女生）的身高（ X ）和体重（ Y ），并画了一张散点图。不考虑性别，假设身高、体重符合二元高斯分布。

1. **归一化**：所有可能取值的概率积分为 1。
2. **边缘分布**：通过对另一个变量的所有可能取值求和得到。

身高的边缘分布：把所有这 100 个人的身高数据拿出来，不管他们的体重是多少，直接画个直方图。

这个直方图就是 $P(\text{身高})$ 。在这个过程中，“体重”这个信息完全忽略了。

举例：

假设我们调查了 100 个人（含男生和女生）的身高（ X ）和体重（ Y ），并画了一张散点图。不考虑性别，假设身高、体重符合二元高斯分布。

3. 求和：考虑性别，男生和女生的身高、体重联合分布都是二元高斯分布，但参数不同。把男生和女生的分布按比例混合，得到一个高斯混合分布（Gaussian Mixture Model）。只有当男生和女生的二元高斯分布参数完全相同时，混合分布才退化为单一高斯分布。

4. 条件分布：想得到在所有身高 180cm 的人中，他们的体重分布是怎样的？先从 100 个人里挑出身高是 180cm 的所有人（比如有 10 个），然后只看这 10 个人的体重数据，画出直方图。这个直方图就是 $P(\text{体重} | \text{身高} = 180\text{cm})$ 。这个分布很可能和整体人口的体重分布完全不同（这 10 个人里可能没有体重很轻的）。

- 1 多元高斯分布的性质
 - 一旦高斯，永远高斯
- 2 高斯过程回归
- 3 高斯过程的定义
- 4 高斯过程回归 (GPR)
- 5 加性高斯噪声
- 6 高斯过程实践
- 7 总结
- 8 应用：贝叶斯全局优化

为什么需要高斯过程？

传统回归模型（如线性回归）输出一个确定的函数，并用参数表示不确定性。

高斯过程（Gaussian Process, GP）则直接在函数空间上定义先验，能给出每个预测点的均值 + 方差，天然提供不确定性估计。

通俗理解：GP 是一个“函数的分布”。当你不知道真实函数是什么时，GP 描述了所有可能的函数形状，并且随着观测数据增多，可能函数的范围逐渐缩小。

直观理解：从多元高斯到无限维高斯？

多元高斯分布：

定义有限个随机变量，它们服从联合正态分布，由均值向量 与协方差矩阵 刻画。

高斯过程：

将维度扩展到无穷——每个输入 x 对应一个随机变量 $f(x)$ ，
任意有限个 $f(x_i)$ 的联合分布都是多元高斯分布。

考虑回归问题:

$$y = f(\mathbf{x}) + \epsilon$$

$$y = \mathbf{w}^T \mathbf{x} + \epsilon \quad (\text{OLS, 岭回归})$$

$$y = \mathbf{w}^T \phi(\mathbf{x}) + \epsilon \quad (\text{核岭回归}).$$

注意: 我们的目标是 <LN4> 从数据中估计概率。到目前为止, 我们已经学习了 <LN8> 最小二乘法 (OLS) 和 (核) 岭回归, 作为回归问题的解决方案。

这些解决方案为我们提供了一个关于单一特定参数 $\mathbf{w}$ 的预测模型。

一般而言, 后验预测分布是:

$$P(Y | D, X) = \int_{\mathbf{w}} P(Y, \mathbf{w} | D, X) d\mathbf{w} = \int_{\mathbf{w}} P(Y | \mathbf{w}, D, X) P(\mathbf{w} | D) d\mathbf{w}$$

但是, 上述公式在闭式解中通常是不可解的。

后验预测分布是：

$$P(Y | D, X) = \int_{\mathbf{w}} P(Y, \mathbf{w} | D, X) d\mathbf{w} = \int_{\mathbf{w}} P(Y | \mathbf{w}, D, X) P(\mathbf{w} | D) d\mathbf{w}$$

上述公式在闭式解中通常是不可解的。

然而，对于高斯似然和先验的特殊情况（这些是岭回归的假设），这个表达式是高斯分布的，可以推导出它的均值和协方差。所以，

$$P(y_* | D, \mathbf{x}) \sim \mathcal{N}(\mu_{y_*|D}, \Sigma_{y_*|D}),$$

其中

$$\begin{aligned}\mu_{y_*|D} &= K_*^T (K + \sigma^2 I)^{-1} y \\ \Sigma_{y_*|D} &= K_{**} - K_*^T (K + \sigma^2 I)^{-1} K_*.\end{aligned}$$

所以，不是执行最大后验估计（MAP）（如岭回归中所做的），我们建模整个分布，且通过直接建模 f （而不是 y ），来忽略 $\mathbf{w}$ 和核技巧！

- 1 多元高斯分布的性质
 - 一旦高斯，永远高斯
- 2 高斯过程回归
- 3 高斯过程的定义**
- 4 高斯过程回归 (GPR)
- 5 加性高斯噪声
- 6 高斯过程实践
- 7 总结
- 8 应用：贝叶斯全局优化

高斯过程的定义

存在的问题: f 是一个无限维的函数! 但是, 多元高斯分布是针对有限维随机向量的。

定义: 高斯过程 (GP) 是一个 (可能是无限的) 随机变量集合, 使得每个有限子集的联合分布都是多元高斯分布:

$$f \sim GP(\mu, k),$$

其中 $\mu(\mathbf{x})$ 和 $k(\mathbf{x}, \mathbf{x}')$ 分别是均值函数和协方差函数!

为了建模预测分布 $P(f_* | \mathbf{x}_*, D)$, 我们可以使用贝叶斯方法, 通过使用**高斯过程先验**:

$$P(f | \mathbf{x}) \sim \mathcal{N}(\mu, \Sigma)$$

并将其条件化于训练数据 D , 以建模 $f = f(X)$ (训练观测的向量) 和 $f_* = f(\mathbf{x}_*)$ (在测试输入下的预测) 的联合分布。

- 1 多元高斯分布的性质
 - 一旦高斯，永远高斯
- 2 高斯过程回归
- 3 高斯过程的定义
- 4 高斯过程回归 (GPR)
- 5 加性高斯噪声
- 6 高斯过程实践
- 7 总结
- 8 应用：贝叶斯全局优化

高斯过程回归 (Gaussian Process Regression, GPR)

假设，在观察训练标签之前，这些标签是从零均值的高斯先验分布中采样得到的：

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \\ y_t \end{bmatrix} \sim \mathcal{N}(0, \Sigma)$$

不失一般性，零均值总是可以通过减去样本均值来达成。

所有训练标签和测试标签都采样自一个 $(n + m)$ -维的高斯分布，其中 n 是训练点的数量， m 是测试点的数量。

注意，我们观察到的真实训练标签 $y_1, \dots, y_n$ 是 $Y_1, \dots, Y_n$ 的样本。

高斯过程回归 (Gaussian Process Regression, GPR)

该分布是否能给我们带来有意义的结果，取决于如何选择协方差矩阵 Σ 。

考虑 Σ 的以下性质：

- 1 $\Sigma_{ij} = E((Y_i - \mu_i)(Y_j - \mu_j))$.
- 2 Σ 总是半正定的。
- 3 $\Sigma_{ii} = \text{Variance}(Y_i)$ ，因此 $\Sigma_{ii} \geq 0$ 。
- 4 如果 Y_i 和 Y_j 非常独立，即 x_i 与 x_j 相差很大，则 $\Sigma_{ij} = \Sigma_{ji} = 0$ 。
- 5 如果 x_i 和 x_j 很相似，则 $\Sigma_{ij} = \Sigma_{ji} > 0$ 。

例：房屋的价格：我的房屋，我邻居的房屋，某位大明星的房屋

可以观察到，这与支持向量机 (SVM) 中的核矩阵非常相似。

高斯过程回归 (GPR)

因此，可以简单地让 $\Sigma_{ij} = K(x_i, x_j)$ 。例如：

- 若使用 RBF 核（即“平方指数核”），则

$$\Sigma_{ij} = e^{\frac{-\|x_i - x_j\|^2}{\sigma^2}}. \quad (1)$$

- 若使用多项式核，则 $\Sigma_{ij} = (1 + x_i^\top x_j)^d$ 。

因此，可以将 Σ 分解为 $\begin{pmatrix} K & K_* \\ K_*^\top & K_{**} \end{pmatrix}$ ，其中：

K 是训练核矩阵， K_* 是训练-测试核矩阵， $K_*^\top$ 是测试-训练核矩阵，而 K_{**} 是测试核矩阵。

潜在函数 f 的（无噪声）值的条件分布可以写为：

$$f_* | (Y_1 = y_1, \dots, Y_n = y_n, x_1, \dots, x_n, x_t) \sim \mathcal{N}(K_*^\top K^{-1} y, K_{**} K^{-1} K_*), \quad (2)$$

其中核矩阵 K_*, K_{**}, K 是 $x_1, \dots, x_n, x_t$ 的函数。

举例：高斯过程寻找失事的船只

- 1 多元高斯分布的性质
 - 一旦高斯，永远高斯
- 2 高斯过程回归
- 3 高斯过程的定义
- 4 高斯过程回归 (GPR)
- 5 加性高斯噪声**
- 6 高斯过程实践
- 7 总结
- 8 应用：贝叶斯全局优化

在许多应用中，观察到的标签可能会受到噪声的影响。如果我们假设这些噪声是独立且零均值的高斯噪声，那么我们观察到的 $\hat{Y}_i = f_i + \epsilon_i$ ，其中 f_i 是真实的（未观察到的 = 潜在的）目标，噪声用 $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$ 表示。

在这种情况下，新的协方差矩阵变为 $\hat{\Sigma} = \Sigma + \sigma^2 \mathbf{I}$ 。

我们首先可以推导这一事实，特别是对于非对角项（即 $i \neq j$ ），因为 $\mathbb{E}[\epsilon_i] = \mathbb{E}[\epsilon_j] = 0$ ，并且我们使用了 ϵ_i 独立于所有其他随机变量的事实。

$$\hat{\Sigma}_{ij} = \mathbb{E}[(f_i + \epsilon_i)(f_j + \epsilon_j)] = \mathbb{E}[f_i f_j] + \mathbb{E}[f_i] \mathbb{E}[\epsilon_j] + \mathbb{E}[f_j] \mathbb{E}[\epsilon_i] + \mathbb{E}[\epsilon_i] \mathbb{E}[\epsilon_j] = \mathbb{E}[f_i f_j] = \Sigma_{ij},$$

对于 Σ 的对角项，即 $i = j$ 的情况，可得到

$$\hat{\Sigma}_{ii} = \mathbb{E}[(f_i + \epsilon_i)^2] = \mathbb{E}[f_i^2] + 2\mathbb{E}[f_i] \mathbb{E}[\epsilon_i] + \mathbb{E}[\epsilon_i^2] = \mathbb{E}[f_i f_i] + \mathbb{E}[\epsilon_i^2] = \Sigma_{ii} + \sigma^2,$$

因为 $\mathbb{E}[\epsilon_i^2] = \sigma^2$ ，这表示 ϵ_i 的方差。

将这个更新后的协方差矩阵代入高斯过程的后验分布中，会得到：

$$Y_* | (Y_1 = y_1, \dots, Y_n = y_n, x_1, \dots, x_n) \sim \mathcal{N}(K_*^\top (K + \sigma^2 I)^{-1} y, K_{**} + \sigma^2 I - K_*^\top (K + \sigma^2 I)^{-1} K_*). \quad (3)$$

实际上，上述方程通常更稳定，因为如果 σ^2 足够大，矩阵 $(K + \sigma^2 I)$ 总是可逆的。

因此，对于预测，可以使用后验均值，且可以获得预测方差，作为对点预测的置信度或（不）确定性的度量。

- 1 多元高斯分布的性质
 - 一旦高斯，永远高斯
- 2 高斯过程回归
- 3 高斯过程的定义
- 4 高斯过程回归 (GPR)
- 5 加性高斯噪声
- 6 高斯过程实践**
- 7 总结
- 8 应用：贝叶斯全局优化

尽管高斯过程回归 (GPR) 是一个非参数模型, 协方差函数 K 仍然有参数。这些参数被称为超参数, 需要从训练数据中学习 (即估计)。

设 θ 为 K 的所有参数的向量, 则 $K = K_\theta$, 我们可以通过最大化边际似然 $P(y | X, \theta)$ 来学习 θ 。

参见《高斯过程机器学习》(GPML) 第 2 章的公式 (2.28)-(2.30),
[href="http://www.gaussianprocess.org/gpml/chapters/RW2.pdf"](http://www.gaussianprocess.org/gpml/chapters/RW2.pdf)>GPML CH 2 (第 19 页)。

一旦你得到了边际似然及其导数, 就可以使用任何现成的求解器, 如 (随机) 梯度下降或共轭梯度下降 (注意: 最小化负对数边际似然)。需要注意的是, 边际似然在其参数上不是一个凸函数, 解最有可能是局部极小值/极大值。为了使这个过程更加稳健, 可以通过不同的初始化重新运行优化算法, 并选择最小/最大返回值。

协方差函数 - 高斯过程模型的核心

高斯过程 (GP) 通过选择合适的协方差/核函数来获得其强大的预测能力。选择协方差函数是在高斯过程学习阶段的模型选择过程。我们有三种不同的方式来选择一个好的协方差函数:

- 专家知识 (非常有用, 但难以获取)
- 贝叶斯模型选择 (可能涉及分析上无法求解的积分!)
- 交叉验证 (耗时, 但实现简单)

一种常用且强大的协方差函数是 RBF (径向基函数), 它为每个特征维度设置不同的长度尺度。

$$k(\mathbf{x}, \mathbf{x}') = \sigma_f^2 e^{-\frac{1}{2}(\mathbf{x}-\mathbf{x}')^T M(\mathbf{x}-\mathbf{x}')} + \sigma_n^2 \delta_{\mathbf{x}, \mathbf{x}'},$$

其中, $M = \text{diag}(\ell)^{-2}$, σ_f^2 是信号方差, ℓ 是长度尺度参数的向量, σ_n^2 是噪声方差。

- 1 多元高斯分布的性质
 - 一旦高斯，永远高斯
- 2 高斯过程回归
- 3 高斯过程的定义
- 4 高斯过程回归 (GPR)
- 5 加性高斯噪声
- 6 高斯过程实践
- 7 总结
- 8 应用：贝叶斯全局优化

高斯过程回归具有以下特点:

- 高斯过程是一种优雅且强大的机器学习方法。
- 我们可以免费的获得预测的（不）确定性度量。
- 高斯过程在训练数据集较小的回归问题中表现非常好。
- 运行时间为 $O(n^3)$ $\leftarrow$ 矩阵求逆（当 $n \gg 0$ 时变得较慢） $\Rightarrow$ 对于较大的 n ，使用稀疏高斯过程。
- 高斯过程在分类问题中稍显复杂（非高斯似然）。
- 我们可以在回归中建模非高斯似然，并进行近似推理，例如计数数据（泊松分布）。
- 高斯过程实现：GPML（MATLAB）、GPys、pyGPs 和 scikit-learn（Python）。

- 1 多元高斯分布的性质
 - 一旦高斯，永远高斯
- 2 高斯过程回归
- 3 高斯过程的定义
- 4 高斯过程回归 (GPR)
- 5 加性高斯噪声
- 6 高斯过程实践
- 7 总结
- 8 应用：贝叶斯全局优化**

应用：贝叶斯全局优化

高斯过程回归的一个有价值的应用是贝叶斯全局优化。
其目标是优化机器学习算法的超参数，以便在固定的验证数据集上表现良好。

假设你有 d 个超参数需要调整，那么数据集由 d 维向量 $x_i \in \mathcal{R}^d$ 组成，每个训练点表示一个特定的超参数设置，而标签 $y_i \in \mathcal{R}$ 表示验证误差。

注意不要混淆，这里的向量 x_i 对应的是超参数设置，而不是数据。

例如，在一个具有多项式核的支持向量机（SVM）中，你有两个超参数：

- 正则化常数 C （也常写作 λ ）和多项式的幂 p 。
- x_i 的第一维可能对应 C 的值，第二维可能对应 p 的值。

应用：贝叶斯全局优化

最初，你在一些随机的超参数设置下训练分类器，并在验证集上评估分类器。这会给你一组训练数据 $x_1, \dots, x_m$ 和标签 $y_1, \dots, y_m$ 。

现在，你可以训练一个高斯过程来预测在任何新超参数设置 x_t 下的验证误差 y_t 。

实际上，你会得到一个均值预测 $y_t = h(x_t)$ 和它的方差 $v(x_t)$ 。

如果你有更多的时间，你现在可以探索一个新的点。最有前景的点是具有最低下置信区间（lower confidence bound, LCB）的点，即：

$$\operatorname{argmin}_{x_t} h(x_t) - \kappa \sqrt{v(x_t)}.$$

常数 $\kappa > 0$ 用于权衡你希望如何在不确定性较大的点（方差较高）之间进行探索，还是希望更多地利用你对当前最佳点的知识，进一步优化已找到的最佳设置。

- 较小的 κ 导致更多的利用
- 较大的 κ 则更积极地探索新的超参数设置

应用：贝叶斯全局优化

算法流程：

Algorithm: $\mathcal{A}, m, n, \kappa$

For $i = 1$ to m

 sample x_i randomly

$y_i = \mathcal{A}(x_i)$

EndFor

For $i = m + 1$ to n

 # 基于 $x_1, \dots, x_{i-1}$ 更新核 K

$x_i = \operatorname{argmin}_{x_t} K_t^\top (K + \sigma^2 I)^{-1} y - \kappa \sqrt{K_{tt} + \sigma^2 I - K_t^\top (K + \sigma^2 I)^{-1} K_t}$



$y_i = \mathcal{A}(x_i)$ # 计算验证误差

Endfor

$i_{best} = \operatorname{argmin}_i \{y_1, \dots, y_n\}$ # 寻找最优的超参



Return $x_{i_{best}}$ # 返回搜索到的最优超参

应用：贝叶斯全局优化



图中显示了在四个训练点（黑色叉号）上训练的高斯过程，并在 $[-5, 5]$ 区间内的一个密集网格上进行评估。红线表示每个测试点的预测均值。阴影灰色区域表示预测的不确定性（与均值的两个标准差范围）。距离训练点较近的测试点（即特征更相似）获得的预测更加确定。

应用：贝叶斯全局优化



贝叶斯优化 (Bayes Optimization, BO) 比网格搜索要快得多

The End