

题目 1

某公司希望建立线性回归模型预测房价，使用均方损失函数，并加入 l_2 正则项（岭回归）。给定以下数据：

- 特征矩阵 $X = \begin{bmatrix} 1 & 2 \\ 1 & 3 \\ 1 & 4 \end{bmatrix}$ ，标签向量 $y = \begin{bmatrix} 5 \\ 7 \\ 9 \end{bmatrix}$ ，正则化系数 $\lambda = 0.1$ 。
- 模型参数 $w = (w_0, w_1)^T$ ，其中 w_0 是截距项。

1. 写出岭回归的目标函数（需展开均方损失项和正则项）。
2. 计算闭式解 $w = (X^T X + \lambda I)^{-1} X^T y$ 。
3. 分析当 λ 增大时，权重 w 的变化趋势。

题目 2

给定核函数 $K(x, z) = (1 + x^T z)^2$ ，其中 $x, z \in \mathbb{R}^2$ 。

1. 证明该核函数是良定义的（即对应的核矩阵半正定）。
2. 对于线性不可分的二维数据集（如下图），说明如何通过此核函数将数据映射到高维空间以实现线性可分。




图 1: 题目 2 数据参考图

3. 若使用核化岭回归模型，闭式解为 $\alpha = (K + \lambda I)^{-1} y$ 。假设训练集为 $\{(1, 2), (2, 3)\}$ ，标签为 $[3, 5]$ ，计算当 $\lambda = 0.1$ 时的核矩阵 K 和参数 α 。

题目 3

某电商平台对用户购买行为进行分析，数据集包含用户的年龄、收入和购买情况（1 表示购买，0 表示未购买）。请使用随机森林分类模型对用户购买行为进行预测。

表 1: 用户购买行为数据

年龄（岁）	收入（万元）	购买情况
20	4	0
25	6	1
30	8	1
35	10	0
40	12	1
45	14	1

1. 请根据上述数据，构建一个随机森林分类模型，并解释模型的构建过程。
2. 使用构建的随机森林模型预测年龄为 32 岁、收入为 9 万元的用户的购买情况，并解释预测过程。
3. 请简要说明随机森林模型相较于单一决策树模型的优势。

题目 4

某研究机构收集了一组数据，用于预测房屋的价格。数据集包含房屋的面积和房龄，以及房屋的价格。请使用高斯过程回归（GPR）模型来预测房屋价格。

1. 请根据上述数据，构建一个高斯过程回归（GPR）模型，并解释模型的构建过程（可写伪代码或者文字描述过程）。
2. 使用构建的 GPR 模型预测面积为 135 平方米、房龄为 3 年的房屋价格，并解释预测过程（文字描述计算过程即可）。
3. 请简要说明高斯过程回归模型的特点和优势。

表 2: 房屋价格数据

面积 (平方米)	房龄 (年)	价格 (万元)
120	5	300
150	3	350
100	8	280
130	2	320
140	4	330
110	6	290

题目 5:

给定以下二维数据集:

$$X = \{(1, 2), (1, 4), (2, 2), (2, 4), (10, 5), (10, 7), (11, 5), (11, 7)\} \quad (1)$$

1. 使用 K-means 算法 ($k = 2$), 手动模拟两次迭代过程:

- 初始质心: $\mu_1 = (1, 2)$, $\mu_2 = (10, 5)$ 。
- 写出每次迭代的聚类分配和更新后的质心。

2. 计算最终聚类结果的 **目标函数值** Z (聚类内平方误差和)。

3. 若初始质心改为 $\mu_1 = (1, 2)$, $\mu_2 = (1, 4)$, 分析算法是否会收敛到相同结果。

题目 6

设计一个简单的前馈神经网络:

- 输入层: 2 个神经元 (输入特征 x_1, x_2)。
- 隐藏层: 2 个神经元, 使用 ReLU 激活函数。
- 输出层: 1 个神经元, 使用 Sigmoid 激活函数。
- 损失函数: 二元交叉熵损失 $\ell(y, \hat{y}) = -[y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})]$ 。

问题:

1. 对于输入 $x = (1, -1)$, 真实标签 $y = 1$, 初始权重和偏置如下:

- $W^{(1)} = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}, b^{(1)} = (0, 0)$
- $W^{(2)} = (1, 1), b^{(2)} = 0$

计算前向传播的输出 $\hat{y}$ 。

2. 计算损失函数对 $W^{(2)}$ 的梯度（反向传播）。
3. 若使用学习率 $\alpha = 0.1$ ，写出 $W^{(2)}$ 的第一次更新后的值。

题目 7

给定以下二维数据集：

$$X = \{(2, 3), (3, 5), (4, 7), (5, 8), (6, 10)\} \quad (2)$$

1. 中心化数据：计算数据集的均值向量 μ ，并写出中心化后的数据集 $\hat{X}$ 。
2. 协方差矩阵：计算中心化后的数据协方差矩阵。
3. 主成分提取：求协方差矩阵的特征值和对应的特征向量，指出第一个主成分方向。
4. 方差解释率：计算前两个主成分的方差贡献率，并解释其意义。