

一、根据表 5-2 的训练数据学习一个朴素贝叶斯分类器，并预测样本 $x=(2,5)^T$ 的类标记 y 。 x_1 和 x_2 为特征在两个维度上的取值。

已知：

- 1. 特征 x_1 的取值集合 $A_1 = \{1,2,3\}$ ，特征 x_2 的取值集合 $A_2 = \{S,M,L\}$ 。
- 2. 类标记 $y \in C = \{1,-1\}$ 。
- 3. 使用拉普拉斯平滑（平滑参数 $\lambda=1$ ）。

表 5-2 训练数据

样本编号	x_1	x_2	y
1	1	S	-1
2	1	M	-1
3	1	M	1
4	1	S	1
5	1	S	1
6	1	S	-1
7	2	M	-1
8	2	M	1
9	2	L	1
10	2	L	1
11	2	L	1
12	3	M	1

样本编号	x_1	x_2	y
13	3	M	1
14	3	L	1
15	3	L	1

二、为什么在高维特征空间或者特征 x 是连续的情况下，用极大似然估计(MLE)方法可能无法进行参数估计？

三、以朴素贝叶斯和逻辑回归为例，试讨论生成模型和判别模型对数据的拟合能力

四、当输入增加新的属性即再增加一维特征时，试讨论生成模型和判别模型的处理方式。

五、根据梯度下降法的原理，假设损失函数 $\ell(w)$ 在点 w^k 处可导且梯度为 $g(w^k) \neq 0$ 。试证明：存在足够小的步长 $\alpha > 0$ ，使得沿负梯度方向更新后的损失函数满足 $\ell(w^k - \alpha g(w^k)) < \ell(w^k)$ 。要求通过泰勒展开的一阶近似进行推导。

六、设损失函数为严格凸二次函数：

$$\ell(w) = \frac{1}{2} w^T A w + b^T w + c,$$

其中 A 为正定矩阵， b 为向量， c 为常数。

(1) 计算梯度 $g(w)$ 和海森矩阵 $H(w)$ 。

(2) 证明牛顿法在该函数上只需一步迭代即可收敛全局最小值 w^* ，并给出迭代公式。

七、假设给定线性回归模型 $y_i = w^\top x_i + \epsilon_i$ ，其中噪声 $\epsilon_i \sim N(0, \sigma^2)$ ，数据集 $\{(x_1, y_1), \dots, (x_n, y_n)\}$ ，且 $x_i \in \mathbb{R}^d$ 。

1. 写出模型的条件概率分布 $P(y_i | x_i, w)$ 。
2. 通过对数似然函数最大化，证明线性回归的闭式解 $w = (XX^\top)^{-1}Xy$ ，其中 $X = [x_1, \dots, x_n]$ ， $y = [y_1, \dots, y_n]^\top$ 。

八、假设线性回归模型 $y = w^\top x + \epsilon$ ，噪声 $\epsilon \sim N(0, \sigma^2)$ ，且参数 w 服从高斯先验 $w \sim N(0, \tau^2 I)$ 。

1. 写出 MAP 估计的目标函数，并推导其闭式解 w_{MAP} 。
2. 对比 MAP 估计与 MLE 估计的闭式解，说明正则化项的作用。

九、考虑带噪声的数据点 $(x_3, y_3) = (1, 1, +1)$ 被错误标记为 -1 ，实际标签应为 $+1$ 。假设训练软间隔 SVM 模型超平面参数为 $w = (1, 1)^\top$, $b = -3$ 。

1. **计算松弛变量**：根据松弛变量定义 $\xi_i = \max(1 - y_i (w^\top x_i + b), 0)$ ，计算该噪声点的 ξ_3 。
2. **分析参数影响**：若调整正则化系数 C ，当 $C \rightarrow 0$ 和 $C \rightarrow +\infty$ 时，超平面会如何变化？结合优化目标解释

原因。

3. **优化问题重构** : 写出软间隔 SVM 的完整优化问题 (含目标函数与约束), 并解释目标中 $\|w\|^2$ 和 $\sum \xi_i$ 的作用。